Czym jest PySpark?

https://databricks.com/glossary/pyspark

…to połączenie API języka Python do wykonywania działań na silniku Apache Spark:



Apache Spark jest napisany w języku Scala. PySpark został wydany w celu wspierania współpracy Apache Spark i Python, w rzeczywistości jest to API Pythona dla Sparka. Ponadto PySpark ułatwia komunikowanie się z Resilient Distributed Datasets (RDD) w językach programowania Apache Spark i Python. Udało się to osiągnąć dzięki wykorzystaniu biblioteki Py4j.

Py4J - to biblioteka zintegrowana z PySpark i umożliwiająca pythonowi dynamiczne łączenie się z obiektami JVM.

PySpark zawiera sporo bibliotek do pisania wydajnych programów:

PySparkSQL	do stosowania analizy podobnej do SQL na ogromnej ilości danych ustrukturyzowanych lub częściowo ustrukturyzowanych. Możemy również używać zapytań SQL z PySparkSQL. Można go również podłączyć do Apache Hive. Można również zastosować HiveQL.
MLlib	to biblioteka uczenia maszynowego (ML) Sparka
GraphFrames	to biblioteka do przetwarzania wykresów

Instalacja Apache Spark z Pythonem (PySpark):

…należy wydać polecenie:

python -m pip install pyspark

Instalowana jest paczka ~ca: 281MB

```
D:\Program Files\Python310>python -m pip install pyspark
Collecting pyspark
  Downloading pyspark-3.2.0.tar.gz (281.3 MB)
     |████████████████████████████████| 281.3 MB 1.9 kB/s
Collecting py4j==0.10.9.2
  Downloading py4j-0.10.9.2-py2.py3-none-any.whl (198 kB)
     |████████████████████████████████| 198 kB 2.2 MB/s
Using legacy 'setup.py install' for pyspark, since package 'wheel' is not installed.
Installing collected packages: py4j, pyspark
    Running setup.py install for pyspark ... done
Successfully installed py4j-0.10.9.2 pyspark-3.2.0
WARNING: You are using pip version 21.2.3; however, version 21.3 is available.
You should consider upgrading via the 'D:\Program Files\Python310\python.exe -m pip install --upgrade pip' command.

D:\Program Files\Python310>
```

…uruchomienie:

pyspark

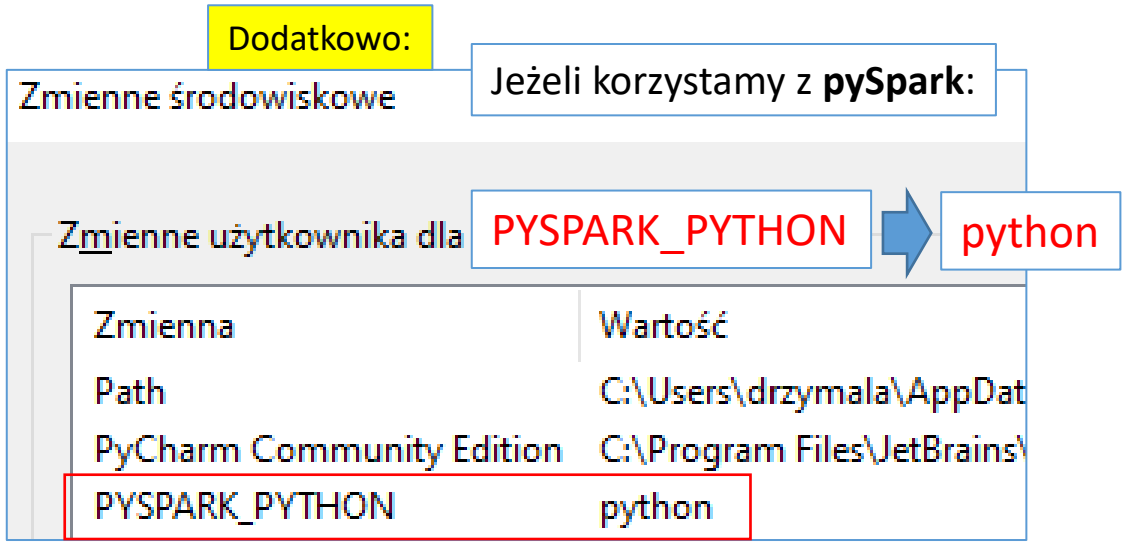
```
D:\Program Files\Python310>pyspark
Python 3.10.0 (tags/v3.10.0:b494f59, Oct  4 2021, 19:00:18) [MSC v.1929 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
WARNING: An illegal reflective access operation has occurred
WARNING: Illegal reflective access by org.apache.spark.unsafe.Platform (file:/C:/BigData/spark3/jars/spark-unsafe_2.12-3.1.2.jar) to constructor jav
WARNING: Please consider reporting this to the maintainers of org.apache.spark.unsafe.Platform
WARNING: Use --illegal-access=warn to enable warnings of further illegal reflective access operations
WARNING: All illegal access operations will be denied in a future release
21/10/21 18:20:58 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
Using Spark's default log4j profile: org/apache/spark/log4j-defaults.properties
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
Welcome to
      ____              __
     / __/__  ___ _____/ /__
    _\ \/ _ \/ _ `/ __/  '_/
   /__ / .__/\_,_/_/ /_/\_\   version 3.1.2
      /_/

Using Python version 3.10.0 (tags/v3.10.0:b494f59, Oct  4 2021 19:00:18)
Spark context Web UI available at http://ANIA:4040
Spark context available as 'sc' (master = local[*], app id = local-1634833261686).
SparkSession available as 'spark'.
>>> 21/10/21 18:21:15 WARN ProcfsMetricsGetter: Exception when trying to compute pagesize, as a result reporting of ProcessTree metrics is stopped

>>>
```

Pojawia się znak zachęty:

Instalacja Apache Spark z Pythonem (PySpark):

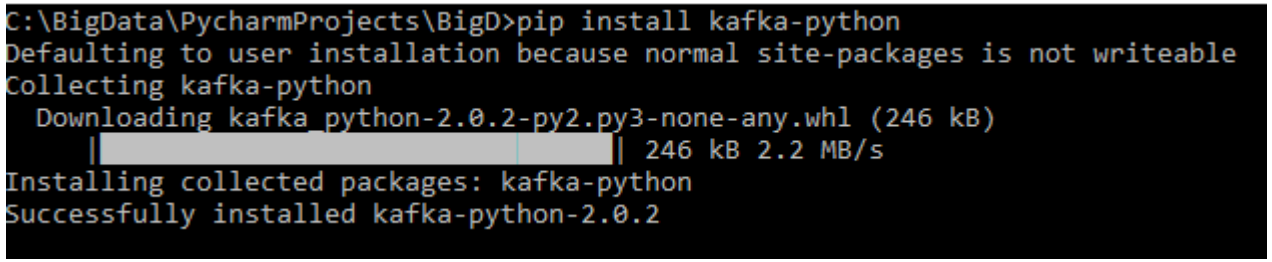


Instalacja Apache Kafka z Pythonem (kafka-python):

Celem przetwarzania strumieni danych potrzebny jest broker np. Kafka.

Do ustawiania wiadomości wysyłanych na topic Kafki z poziomu języka Kafka należy zainstalować bibliotekę:

pip install kafka-python



Jak zaimportować PySpark w skrypcie Pythona

https://sparkbyexamples.com/pyspark/how-to-import-pyspark-in-python-script/

Czym jest SparkSession?

https://sparkbyexamples.com/spark/sparksession-explained-with-examples/

po pomyślnym zainstalowaniu Sparka w systemie LUW mogą wystąpić problemy „ No module named pyspark” podczas importowania bibliotek PySpark w Pythonie

Uwaga: Nie używaj Python shell ani Python command nie uruchamiaj programu PySpark.

Procedura:

1. Upewnij się, że instalacja PySpark jest prawidłowa

2. Importuj PySpark w Pythonie za pomocą findspark

pip install findspark

```
C:\Users\drzymala>pip install findspark
Collecting findspark
  Downloading findspark-1.4.2-py2.py3-none-any.whl (4.2 kB)
Installing collected packages: findspark
Successfully installed findspark-1.4.2
```

Findspark przeszukuje instalację pyspark na serwerze i dodaje ścieżkę instalacji **sys.path** w czasie wykonywania, aby można było zaimportować moduły PySpark.

sprawdzenie poprawność importów PySpark

```
import findspark
findspark.init()

import pyspark
from pyspark.sql import SparkSession
spark = SparkSession.builder.master("local[1]").appName("SparkByExamples.com").getOrCreate()
```

3. Ustawianie zmiennych środowiskowych PySpark

pip show pyspark

```
C:\Users\drzymala>pip show pyspark
Name: pyspark
Version: 3.2.0
Summary: Apache Spark Python API
Home-page: https://github.com/apache/spark/tree/master/python
Author: Spark Developers
Author-email: dev@spark.apache.org
License: http://www.apache.org/licenses/LICENSE-2.0
Location: d:\program files\python310\lib\site-packages
Requires: py4j
Required-by:
```

```
set SPARK_HOME=C:\apps\opt\spark-3.2.0-bin-hadoop2.7
set HADOOP_HOME=%SPARK_HOME%
set PYTHONPATH=%SPARK_HOME%/python;%SPARK_HOME%/python/lib/py4j-0.10.9-src.zip;%PYTHONPATH%
```